

國立台南大學資訊工程學系
116 級畢業專題期中進度報告

以 Slurm-on-Kubernetes 為核心之共享 GPU

工作負載彈性排程平台

Elastic Slurm Scheduling on Kubernetes
for Shared GPU Workloads

專案編號：NUTN-CSIE-PRJ-116-016

組員： S11259043 鄭珽升

S11259033 蕭友翰

指導老師： 陳宗禧 教授

中華民國 115 年 6 月

國立台南大學資訊工程學系
畢業專題期中進度報告審定書

以 Slurm-on-Kubernetes 為核心之共享 GPU

工作負載彈性排程平台

Elastic Slurm Scheduling on Kubernetes
for Shared GPU Workloads

學生 學號：S11259043 姓名：鄭珽升

學號：S11259033 姓名：蕭友翰

所提之報告內容符合本學系大學部畢業專題實作標準

指導教授：_____

系主任：_____

中華民國 115 年 6 月

成果貢獻摘要

本計畫已達成下列重要成果：

- 建立可實際運作之共享 GPU AI 工作負載彈性排程平台，整合 Slurm 批次排程與 Kubernetes 容器管理。
- 實現 CPU/GPU 計算節點自動彈性擴縮，依工作佇列長度動態啟停節點，有效降低硬體閒置浪費。
- 完成 GPU 資源切分機制 MPS，支援多個小型工作共享同一張 GPU，提升 GPU 使用效率。
- 實現風險敏感分佈式深度強化學習排程，模型可在真實系統中參與工作優先順序與資源放置決策。
- 建立系統監控與視覺化介面，即時呈現工作佇列、節點狀態、GPU 使用率及模型決策資訊。
- 完成平台穩定性修正（節點狀態同步、GPU 資源描述一致性），並通過實機驗證。

摘要

本專題開發一套以 Slurm-on-Kubernetes 為核心之共享 GPU AI 工作負載彈性排程平台，旨在解決研究室共享主機環境中 GPU 利用率不足及資源閒置等問題。使用者可以熟悉的方式提交工作，系統則在背後自動完成節點啟動、工作排序、GPU 切分分配與執行監控。在智慧決策層面有採用多種深度強化學習方法，使模型學習每個排程決策可能造成的結果分布，並加入風險敏感判斷，偏向選擇在壞情況下也較穩定的資源配置方案。

關鍵詞：GPU 資源排程、Kubernetes、Slurm、深度強化學習、彈性擴縮

目錄

成果貢獻摘要	I
摘要.....	II
目錄.....	III
第一章 動機與問題	1
1.1 研究動機.....	1
1.2 研究問題.....	1
第二章 文獻探討	2
2.1 高效能運算排程器 (Slurm)	2
2.2 容器化與 Kubernetes	2
2.3 GPU 資源共享技術.....	2
2.4 深度強化學習於資源排程.....	2
第三章 研究方法	4
3.1 系統整體架構.....	4
3.2 排程與資源分配流程.....	4
3.2.1 基本排程規則.....	4
3.2.2 智慧決策模型.....	5
3.2.3 指定資源配置機制.....	5
3.3 GPU 資源共享方法.....	5
3.4 模型訓練與評估方法.....	6
3.4.1 訓練與評估管線.....	6
3.4.2 模擬配對基準測試.....	7
3.4.3 實機 A/B 測試	7
第四章 結果與討論	8
4.1 平台建置成果.....	8
4.1.1 平台建置與操作.....	8
4.1.2 監控與展示介面.....	8
4.2 評估結果.....	9
4.2.1 模擬環境評估.....	9
4.2.2 實機 A/B 測試結果	9
4.3 結論.....	9
4.4 後續改進.....	10
第五章 參考文獻	11

第一章 動機與問題

1.1 研究動機

近年來，人工智慧研究越來越依賴 GPU 進行訓練、推論與資料處理。然而在一般研究室的共享主機環境中，常常面臨以下困境：

- 一張 GPU 只給一個工作使用，實際利用率不高。
- 沒有工作時，系統仍然維持大量資源待命，造成硬體閒置。

目前常見的系統大多只擅長其中一件事。容器平台如 Kubernetes 擅長自動啟動與回收資源，但對研究工作常見的 GPU 分配、批次排程與多使用者管理支援較弱；相對地，傳統高效能運算排程器 Slurm 雖擅長管理工作佇列與硬體資源，但對彈性擴縮與雲端式管理不夠方便。

因此，本專題希望結合兩者優點，建立一套既能保有研究者熟悉的工作提交流程，又能做到動態分配 CPU、GPU 與儲存資源的系統。進一步地，我們也希望導入機器學習方法，讓系統可以根據目前工作佇列狀態與硬體使用情形，自動做出更合理的資源分配決策。

1.2 研究問題

本計畫主要探討以下幾個問題：

- 如何在容器化叢集(Kubernetes)上建立一套適合研究工作的排程平台。
- 如何根據工作數量，自動擴縮 CPU 與 GPU 計算節點。
- 如何讓多個較小的 GPU 工作共享同一張顯示卡，以提升使用效率。
- 如何利用深度強化學習模型，協助系統決定哪些工作應優先執行，以及應使用哪些硬體資源。
- 如何在模型判斷不可靠時，讓系統自動回到較穩定的基本排程方式。

第二章 文獻探討

2.1 高效能運算排程器 (Slurm)

Slurm Workload Manager [1] 是目前高效能運算 (HPC) 叢集最廣泛使用的工作排程系統之一。它提供完整的工作提交、佇列管理、資源限額與帳務管理功能，並支援 GPU 資源分配。其以「節點」為基礎的資源模型非常適合研究工作環境，且已有廣泛的使用者社群與文件支援。然而 Slurm 原生設計以固定實體節點為主，對彈性擴縮與容器化整合的支援相對有限。

2.2 容器化與 Kubernetes

Kubernetes [6] 是目前最主流的容器編排平台，能夠自動管理容器的部署、擴縮與健康監控。Kubernetes 的 Cluster Autoscaler 可根據工作負載自動增減節點，非常適合需要彈性資源的場景。然而 Kubernetes 原生的排程器 (kube-scheduler) 以服務導向設計為主，對批次工作、GPU 共享與研究工作特有的排程需求支援不足。因此有多項研究嘗試將 Slurm 與 Kubernetes 整合，以結合兩者優點。

2.3 GPU 資源共享技術

NVIDIA 提供多種 GPU 資源共享技術，包括 Time-Slicing、Multi-Process Service (MPS) [13] 以及 Multi-Instance GPU (MIG)。MPS 允許多個 CUDA 程式同時共享一張 GPU 的運算資源；MIG 則在硬體層面將 GPU 切分成獨立的分區，提供更強的隔離性。本系統目前採用基於 MPS 的方式，讓多個較小的工作共享同一張 GPU，以提升整體使用效率。

2.4 深度強化學習於資源排程

近年來已有多項研究將深度強化學習應用於資源排程問題，包括資料中心工作排程、雲端資源分配等。然而多數工作採用期望值導向 (expectation-based) 的獎勵函數，僅最佳化平均表現，忽略了不確定情境下的風險。Ma et al. [15] 提出的 Distributional Soft Actor-Critic for Risk-Sensitive RL (RDSAC) 透過分佈式 critic 估計每個動作的 reward 分布，並結合 Soft Actor-Critic (SAC) [16] 的最大熵探索框架來實現風險敏感決策。相較於僅看平均值的方法，RDSAC 能夠同時考量好情況與壞情況，根據風險偏好做出更穩健的選擇，非常適合共享 GPU 平台等對穩定性有較高要求的場景。

Soft Actor-Critic (SAC) 採用 scalar twin-Q 與離散 categorical actor。在最大熵框架下，SAC 同時最佳化期望累積回報與策略熵，使策略兼顧效能與充分探索：

$$J = \sum_t E[r_t + \alpha H_t]$$

其中 α 為可自動調整的溫度參數， H_t 為步驟 t 的策略熵 $H(\pi(\cdot|s_t))$ 。Critic 採用雙 Q-network（取最小值），並以 soft 貝爾曼目標更新：

$$y = r + \gamma(1 - d)V(s')$$

$$V(s') = \sum_{a'} \pi(a'|s') [\min Q(s', a') - \alpha \ln \pi(a'|s')]$$

$$L_Q = \sum_i E[(Q_i(s, a) - y)^2]$$

策略（actor）最小化以下目標，在每個合法動作上對熵正則化（鼓勵探索）與 Q 值最大化取得平衡：

$$L_\pi = E_s \sum_a \pi(a|s) [\alpha \ln \pi(a|s) - \min Q(s, a)]$$

將此一風險敏感分布式 SAC（簡稱 RDSAC）作為核心排程演算法。我們把 GPU 工作排程建模為馬可夫決策過程 (MDP)：狀態 s 為佇列中前 16 個待排工作的特徵與叢集 MPS 使用狀況，動作 a 為「選擇某個工作並指定其節點與 GPU 放置」或不放置 (no-op)，獎勵則以負的工作完成時間 (JCT) 為主。

RDSAC 的特點是不只估計回報的平均值，而是估計整個回報的機率分布。它在最大熵框架下，把 soft return 拆成兩個分布：獎勵回報分布 Z_R 與熵回報分布 Z_H ，兩者各以隱式分位數網路 (IQN) 表示，並以 quantile Huber 損失回歸。某個狀態-動作的綜合價值為兩者期望值之和：

$$Q(s, a) = E[Z_R(s, a)] + \alpha E[Z_H(s, a)]$$

其中 α 為自動調整的溫度參數，控制探索程度。為了讓策略對「壞情況」更敏感，RDSAC 在策略目標中對獎勵分布 Z_R 套用風險扭曲函數 ρ 。本專題採用條件風險值 (CVaR)：只取分布下尾 β 比例的平均，使策略偏好最差情況較不嚴重的放置決策：

$$\rho_\beta[Z] = \frac{1}{\beta} \int_0^\beta F_Z^{-1}(\tau) d\tau$$

其中 β 越小越保守； $\beta = 1$ 時 CVaR 退化為一般平均。由於排程動作是離散的，因此將原始論文連續控制的高斯 actor 改寫為顯式的 categorical actor。策略以最小化下式的目標更新，對每個合法動作同時權衡熵（鼓勵探索）與風險調整後的回報：

$$J_\pi(s) = \sum_a \pi(a|s) [\alpha \ln \pi(a|s) - \rho(Z_R(s, a)) - \alpha E[Z_H(s, a)]]$$


直覺上，當風險模式設為 mean ($\beta = 1$) 時等同風險中立、只看平均；設為 cvar 時則會主動避開可能造成長尾延遲（如 straggler、冷啟動 worker、執行時間離群）的放置決策，特別適合對穩定性要求高的共享 GPU 平台。

第三章 研究方法

3.1 系統整體架構

本系統的核心概念是把「批次工作排程」與「彈性資源管理」結合起來。使用者仍然以熟悉的方式提交工作，而系統在背後自動處理工作排序、節點啟動、GPU 分配與執行監控。如下圖 1 所示，整體系統包含下列幾個部分：

- (1) 工作提交入口：提供使用者提交與查詢工作的介面。
- (2) 中央排程控制：負責接收工作、維護佇列、決定優先順序。
- (3) CPU 與 GPU 計算節點：實際執行工作的運算資源。
- (4) 彈性控制模組：根據佇列長度與執行狀態，自動啟動或回收計算節點。
- (5) 智慧決策模組：利用強化學習模型協助判斷工作排序與資源配置。
- (6) 監控與追蹤模組：記錄系統狀態、工作過程與資源使用情況。



【圖 1】系統整體架構圖

3.2 排程與資源分配流程


目前系統的決策流程分成三層：

3.2.1 基本排程規則

當使用者提交工作後，系統先補齊必要資訊，並根據幾個簡單穩定的規則計算工作的優先程度。這些規則主要考慮：工作是否適合目前剩餘的 GPU 資源、是否造成資源碎片化、以及較短的工作是否應優先執行。此層作為系統的保底機制，即使智慧模型失效，系統仍可正常運作。

3.2.2 智慧決策模型

在基本規則之外，加入深度強化學習模型，讓系統可根據「目前有哪些工作在等待」、「哪些節點正在執行」、「GPU 尚有多少可分配空間」等資訊，進一步判斷哪一個工作應優先處理、是否需要額外提高優先順序，以及工作比較適合放到哪一個節點上。整體決策流程如下圖 2 所示：




【圖 2】工作提交後的決策流程圖

3.2.3 指定資源配置機制

除了影響工作的先後順序外，系統也能先暫時保留工作，再根據模型決定其應放到哪一台節點上。這樣的做法讓模型的判斷不只停留在「哪個工作先跑」，而是更進一步參與「工作要放在哪裡跑」的決策。

3.3 GPU 資源共享方法

為提升利用率，可以透過 MPS (Multi-Process Service) 讓多個較小的工作共享同一張 GPU。以目前的系統設定為例，一張 GPU 可切成多個可分配單位，使用者可依需求申請 0.25、0.50、0.75 或整張卡，如下圖 3 所示：



【圖 3】GPU 資源切分示意圖

3.4 模型訓練與評估方法

將比較三種排程方式，採完全相同的訓練配方，僅調整指令參數，以區分各機制的貢獻：

- **啟發式 Score**：以加權線性組合公式計算工作優先級，分數越高代表該工作越值得優先排程。五個因子及對應權重說明如下表，預設不啟用 topology 和 runtime fit 兩項。

因子	係數	定義
MPS fit	$\alpha = 0.40$	$mps_req/100 \in [0, 1]$ 。沒給=1.0，超過=0.0。
VRAM fit	$\beta = 0.20$	$(1 - (\text{fit_tier} - req))/max_tier \in [0, 1]$ 。 依 job 需求選最小可用 VRAM tier，沒給=0.5。
Topology	$\gamma = 0.00$	保留欄位，固定回傳 0.5
Fragmentation	$\delta = 0.20$	$4(x - 1), x = mps_req/100$ 。mps_req=0 或滿載 →0.0；mps_req=50%→最高懲罰≈-1.0
Runtime fit	$\varepsilon = 0.00$	$(1 - \text{pred_seconds})/fallback(14400s)$ 。 predictor 不可用=0.5；鼓勵短工作先排。

【表 1】啟發式因子與係數定義

- **SAC**：純量 twin-Q critic，無分布式 critic 或風險機制，作為 RDSAC 的對照基準。
- **RDSAC**：忠實實作 Ma et al. [15] 的離散版本，雙分布 IQN critic ($Z_R + Z_H$) 加風險扭曲，提供 mean（風險中立）與 cvar ($\beta = 0.25$ ，下尾風險敏感) 兩種模式。

3.4.1 訓練與評估管線

直接在實際環境從頭訓練的話，強化學習需要數十萬到數百萬個 transition，而真實叢集一個編排決策對應一個跑數分鐘至數小時的任務，湊滿樣本要等數月，因此採 sim-to-real 兩段式：

- (1) 在模擬環境大量訓練，產出基本模型 (checkpoint)
- (2) 上線部署，記錄真實叢集 (observation, action, reward) 資料
- (3) RLPD (Reinforcement Learning with Prior Data) [25] 用真實資料把模擬的基本模型微調成真實環境策略

3.4.2 評估指標

在評估一個排程策略時都有主要指標平均工作完成時間(mean JCT)和尾部延遲指標 p95/p99 JCT、CVaR(0.25)。因為從 mean JCT 難以看出把 straggler、queue starvation、head-of-line blocking 等罕見問題，即「多數 job 正常、少數被拖很慢」的情況。這些慢 job 幾乎不影響 mean JCT，但主導使用者體感。而 p95/p99 指標專門抓「最差 5%/1% 有多慢」，正是 mean 結構上看不到的那段。此外，RDSAC-cvar 的設計目標就是優化回報下尾(=JCT 上尾)；只測量 mean 等於拿不會動的尺去量專門改尾部的的方法，結構上必然測不出差異。

3.4.3 模擬配對基準測試

使用相同亂數種子(seed)對每種排程法做配對比較，降低 trace 隨機性造成的誤差。其中 $\Delta JCT\% = \frac{score-model}{score} \times 100\%$ ，負值代表模型的 JCT 較高、較差。每個 trace 取 50 個 job，訓練 100,000 步（含 curriculum n_jobs 10→30→50，fixed- $\alpha=0.05$ ）。評估工作在兩個工作負載家族 Philly [26] 和 Alibaba [27]、各 5 個亂數種子下進行。

3.4.4 實機 A/B 測試

在實驗室環境 (RTX 4070 + RTX 3080) 提交 cuBLAS sgemm 工作，做配對 A/B 測試。驗證以 3 個訓練亂數種子 (42/43/44) 各跑一次四方 A/B，確保對訓練種子穩健。每個 GPU 工作用同一條 stream 在四種方法 (score/SAC/RDSAC-mean/RDSAC-cvar) 各重放一次。並且減少叢集飄移(drift)的偏差，即 GPU 跑久了會變快。若一種方法整段跑完才換下一種，drift 會和方法混淆，故改用 Round Robin 交錯方法順序、每方法跨多輪並輪換各個位置，把飄移誤差平均掉。

第四章 結果與討論

4.1 平台建置成果

目前系統已完成主要功能建置，並通過實機驗證。主要成果如下：

4.1.1 平台建置與操作


已完成主要平台建置，並整理出清楚的部署與驗證流程如下表 1。使用者可透過登入節點提交工作，系統則自動在背後完成節點啟動、工作排程、GPU 分配與結果輸出。

工作項目	預期目標	目前狀態
CPU/GPU 資源自動調整	依工作量自動擴縮節點	已完成
系統監控與視覺化	可觀察佇列、節點狀態與 GPU 使用	已完成
啟發式基準排程	建立穩定的啟發式 score 基準	已完成
SAC 與 RDSAC 排程	已上線	已完成
實機 A/B 測試架構	配對比較 DRL vs. 啟發式	已完成
RLPD	用真實資料把模擬的基本模型微調成真實環境策略	未完成

【表 1】預期工作項目與達成狀態

4.1.2 監控與展示介面

見下圖 4，目前系統已可清楚呈現：等待中的工作數量、各計算節點是否已啟動、GPU 的實際使用率、MPS 資源的使用情形，以及 DRL 最近是否有做出決策。



【圖 4】系統監控畫面截圖

4.2 評估結果

在模擬環境和實機環境的評估結果如下。

4.2.1 模擬環境評估

模擬評估在三個訓練亂數種子，使用和啟發式 score 的 JCT 差距百分比如下表 2，結果顯示沒有 DRL 演算法可以穩定超越 score：

資料集	排程	JCT	p95	p99	Δ JCT%
philly	SAC	2.3±0.1	11.4±0.5	28.4±1.5	-11.8±4.2
philly	RDSAC-mean	2.6±0.1	11.7±1.2	41.0±8.8	-23.1±7.4
philly	RDSAC-cvar	2.1±0.1	9.3±1.1	30.4±3.8	-4.1±4.6
ali	SAC	1.2±0.1	5.5±1.2	21.1±0.3	-15.2±17.5
ali	RDSAC-mean	1.4±0.1	6.6±0.5	22.7±2.5	-32.7±10.4
ali	RDSAC-cvar	1.1±0.1	4.3±0.9	20.4±0.6	-12.0±12.0

【表 2】全方法的模擬環境評估結果

4.2.2 實機 A/B 測試結果

在實機上評估四種排程方法的差異，拿三個亂數種子(42,43,44)來做整合評估。參考下表 3，可以發現 Score 略勝 DRL 方法，而 DRL 策略的排名大致為 RDSAC-mean>RDSAC-cvar>SAC。

排程／指標	JCT	p95	p99	CVaR	Δ JCT%
Score	169.4±1.4	398.9±0.9	429.8±3.7	375.8±1.1	-
SAC	175.6±1.4	403.9±1.6	431.2±1.9	381.7±1.9	-3.6±0.4
RDSAC-mean	173.5±0.9	399.3±3.2	430.0±5.1	377.7±3.1	-2.4±1.4
RDSAC-cvar	175.3±0.3	404.7±0.9	430.4±3.6	381.9±0.5	-3.4±1.0

【表 3】全方法的實機評估結果 (mean±std)

4.3 結論

本專題已成功建立可上線運作的智慧排程平台，並完成受控三方對照實驗，主要結論如下：

- DRL 客製化 Slurm 排程插件可在實機正確運作。
- 實機評估時，還沒有 DRL 演算法贏過啟發式 score。

4.4 後續改進

以下規劃幾種改進措施增強研究貢獻和訓練評估效果：

- 補強 baseline：補充 FCFS/SJF 等基本評估結果。
- 使用 RLPD 從基礎模型微調成實機策略，也許有機會贏過啟發式。

第五章 參考文獻

1. SchedMD. (n.d.). *Slurm workload manager documentation*. <https://slurm.schedmd.com/>
2. SchedMD. (n.d.). *Slurm plugin API*. <https://slurm.schedmd.com/plugins.html>
3. The Kubernetes Authors. (n.d.). *Kubernetes documentation*. <https://kubernetes.io/docs/>
4. Nolar. (n.d.). *Kopf: Kubernetes operator pythonic framework* [Computer software]. GitHub. <https://github.com/nolar/kopf>
5. *Converged computing: Integrating HPC and cloud native*. (2024). IEEE Computer Society. <https://www.computer.org/csdl/magazine/cs/2024/03/10770850/22fgId5NFpC>
6. *Kubernetes v1.35: Introducing workload-aware scheduling*. (2025, December 29). The Kubernetes Blog. <https://kubernetes.io/blog/2025/12/29/kubernetes-v1-35-introducing-workload-aware-scheduling/>
7. SchedMD. (n.d.). *Slinky* [Computer software]. GitHub. <https://github.com/slinkyproject>
8. Penso, V. (n.d.). *Prometheus Slurm exporter* [Computer software]. GitHub. <https://github.com/vpenso/prometheus-slurm-exporter>
9. Amazon Web Services. (n.d.). *AWS ParallelCluster* [Computer software]. GitHub. <https://github.com/aws/aws-parallelcluster>
10. Texas Advanced Computing Center. (n.d.). *Lmod: An environment module system* [Computer software]. GitHub. <https://github.com/TACC/Lmod>
11. The Kubernetes Authors. (n.d.). *Scheduler configuration: Scoring*. Kubernetes. <https://kubernetes.io/docs/reference/scheduling/config/>
12. Grafana Labs. (n.d.). *Grafana*. <https://grafana.com/>
13. NVIDIA. (n.d.). *Multi-Process Service (MPS)*. NVIDIA Documentation. <https://docs.nvidia.com/deploy/mps/>
14. The Kubernetes Authors. (n.d.). *kube-state-metrics* [Computer software]. GitHub. <https://github.com/kubernetes/kube-state-metrics>
15. Ma, X., Xia, L., Zhou, Z., Yang, J., & Zhao, Q. (2020). *DSAC: Distributional soft actor-critic for risk-sensitive reinforcement learning* [Preprint]. arXiv. <https://arxiv.org/abs/2004.14547>
16. Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*. <https://arxiv.org/abs/1801.01290>
17. Christodoulou, P. (2019). *Soft actor-critic for discrete action settings* [Preprint]. arXiv. <https://arxiv.org/abs/1910.07207>
18. Dabney, W., Ostrovski, G., Silver, D., & Munos, R. (2018). Implicit quantile networks for distributional reinforcement learning. In *Proceedings of the 35th*

- International Conference on Machine Learning (ICML).*
<https://arxiv.org/abs/1806.06923>
19. Reinforcement learning for AI as a service: CPU–GPU task scheduling for preprocessing, training, and inference tasks. (n.d.). IEEE.
<https://ieeexplore.ieee.org/abstract/document/10976623>
 20. Abdul Majeed, A., et al. (n.d.). Scheduling techniques of AI models on modern heterogeneous edge GPU—A critical review. IEEE.
<https://ieeexplore.ieee.org/abstract/document/11354153>
 21. Lipe, E., et al. (n.d.). Energy-efficient scheduling of AI/ML workloads on multi-instance GPUs with dynamic repartitioning. IEEE.
<https://ieeexplore.ieee.org/abstract/document/11044810>
 22. Sedighi, H., et al. (n.d.). Dynamic task scheduling and adaptive GPU resource allocation in the cloud. IEEE.
<https://ieeexplore.ieee.org/abstract/document/11261404>
 23. Wang, X., et al. (n.d.). Dynamic GPU scheduling with multi-resource awareness and live migration support. IEEE.
<https://ieeexplore.ieee.org/abstract/document/10091187>
 24. Chab, R., et al. (2025). Algorithmic techniques for GPU scheduling: A comprehensive survey. *Algorithms*, 18(7), 385. <https://www.mdpi.com/1999-4893/18/7/385>
 25. Philip J. Ball, et al. (2023). *Efficient Online Reinforcement Learning with Offline Data* [Preprint]. arXiv. <https://arxiv.org/abs/2302.02948>
 26. Microsoft Research. (n.d.). *Philly traces* [Data set]. GitHub.
<https://github.com/msr-fiddle/philly-traces>
 27. Alibaba. (n.d.). *Cluster data: Production cluster traces* [Data set]. GitHub.
<https://github.com/alibaba/clusterdata>